

---

---

# Entrepôt de données

— Par Rihab Mersni —

---

---

Par Rihab Mersni

# Plan

Entrepôt de données

- Contexte
  - Problématique
  - Définition
  - DW VS SGBD
  - Architecture système décisionnel
  - Datamart
-

# Contexte

**Besoin:** prise de décisions

**Pourquoi:** besoin de la matière (des informations , des données, es exemples ...)

**Qui:** les décideurs (tous les métiers même les informaticiens)

**Comment:** préparer les données pour les présenter sous formes compréhensive et parlante



# Contexte

## Types de données

- Bases de données (Oracle, SQL Server)
- Fichiers (Excel, texte ...)
- Sites web
- Médias (journaux, magazines , ...)



# Contexte

## Caractéristiques de ces données

- Distribuées: systèmes éparpillés (différentes machines)
- Hétérogènes: systèmes et structures de données différents (sql server //oracle, Microsoft //Linux)
- Détaillées: trop d'informations techniques ou qui n'ont pas de relation avec le contexte étudié.
- Peu/pas adaptées à l'analyse : Conception spécifique pour chaque application qui peut être mal conçu pour l'analyse (les requêtes lourdes peuvent bloquer le système transactionnel)
- **Volatiles**: pas d'historisation systématique (Excel par exemple )



# Problématique

## Comment répondre aux demandes des décideurs?

- En donnant un accès rapide et simple à l'information
- En présentant les données sous forme lisible et significatifs
- En donnant une vision transversale des données de l'entreprise (intégration de différentes bases de données).



# Problématique

**Mettre en place un SI dédié aux applications décisionnelles : un entrepôt de données (Data warehouse) pour transformer des données de production en informations stratégiques.**



# Entrepôt de données : Data Warehouse

Définition selon *Bill Inmon*

"collection de données orientée sujet, non volatile, intégrée et variant dans le temps à l'appui des décisions de la direction"

**Principe:** mettre en place une base de données utilisée à des fins d'analyse




# Entrepôt de données : Caractéristiques

## **Données orientées sujet**

- Regroupe les informations des différents métiers
- Ne tiens pas compte de l'organisation fonctionnelle des données.

# Entrepôt de données : Caractéristiques



- Normalisation des données
- Définition d'un référentiel unique



# Entrepôt de données : Caractéristiques

## Données non volatiles

- Traçabilité des informations et des décisions prises
- Copie des données de production (à jour)



# Entrepôt de données : Caractéristiques

## Données datées

- Les données persistent dans le temps
- Mise en place d'un référentiel temps

Base de  
production

Image de la base en Mai 2005

Répertoire

| Nom    | Ville |
|--------|-------|
| Dupont | Paris |
| Durand | Lyon  |

Image de la base en Juillet 2006

Répertoire

| Nom    | Ville     |
|--------|-----------|
| Dupont | Marseille |
| Durand | Lyon      |

Entrepôt  
de  
données

Calendrier

| Code | Année | Mois    |
|------|-------|---------|
| 1    | 2005  | Mai     |
| 2    | 2006  | Juillet |


Répertoire

| Code | Année  | Mois      |
|------|--------|-----------|
| 1    | Dupont | Paris     |
| 1    | Durand | Lyon      |
| 2    | Dupont | Marseille |

# Entrepôt de données VS Base de donnée transactionnelle

## SGBD et DW

OLTP: On-Line  
Transactional  
Processing



# Entrepôt de données VS Base de donnée transactionnelle

## OLTP VS DW

| OLTP                                                    | DW                                    |
|---------------------------------------------------------|---------------------------------------|
| Orienté transaction                                     | Orienté analyse                       |
| Orienté application                                     | Orienté sujet                         |
| Données courantes                                       | Données historisées                   |
| Données détaillées                                      | Données agrégées                      |
| Données évolutives                                      | Données statiques                     |
| Utilisateurs nombreux,<br>administrateurs/opérationnels | Utilisateurs peu nombreux,<br>manager |
| Temps d'exécution: court                                | Temps d'exécution: long               |

---

---

# Architecture système décisionnel

---

---


# Architecture système décisionnel

Tout système décisionnel est architecturé globalement de la même façon :


- En amont un accès au système transactionnel en lecture seule
- Un **DW** fusionnant les données requises
- Un **ETL** permettant d'alimenter le DW à partir des données existantes
- Des applications d'exploitation de *reporting*, exploration et/ou prédiction
- D'éventuels **Data Mart** permettant de simplifier le DW en vue de certaines applications



# Architecture système décisionnel



# Architecture système décisionnel : ETL



# Architecture système décisionnel

Principaux types d'outils d'une architecture décisionnel

- ETL
- *Reporting*
- Exploration
- Analyse

# Architecture système décisionnel

- L'ETL (*Extraction Transformation Loading*)

Ils permettent de concevoir et d'organiser les processus de migration du système transactionnel vers le système décisionnel.



# Architecture système décisionnel

- Reporting

Ils permettent :

- la création graphique de rapport
- l'accès aux sources de données via des API dédiées
- ...



# Architecture système décisionnel

- Outils d'exploration

Ils permettent de manipuler interactivement des cubes multidimensionnels (choix des dimensions à croiser et des types d'agrégations à effectuer)



# Architecture système décisionnel

- Analyse
  - Ils permettent l'analyse statistique de données.



---

---

# Conception d'un système décisionnel

---

---

The slide features decorative elements consisting of two horizontal teal bars at the top and bottom, and two short horizontal olive-green bars positioned below the main title.



# Conception d'un système décisionnel

Un projet de système décisionnel se structure selon quatre grands axes :

1. Étude des besoins et de l'existant
2. Modélisation et conception
3. Implémentation du data warehouse
4. Implémentation des outils d'exploitation

# Conception d'un système décisionnel

1. Étude des besoins et de l'existant
  - Étude des besoins utilisateurs
  - Étude des données existantes
  
2. Modélisation et conception
  - Modélisation dimensionnelle
  - Architecture technique
  - Spécification des outils d'exploitation

# Conception d'un système décisionnel

## 3. Implémentation du data warehouse

- Implémentation du DW et des DM
- Mise en place de l'ETL

## 4. Implémentation des outils d'exploitation

- Implémentation des outils de *reporting*
- Implémentation des outils d'exploration
- Implémentation des outils de prédiction

---

---

# Datamart

— Datawarehouse et Datamart —

---

---

# Datamart

## Pourquoi des data marts ?

Les *data marts* sont destinés à pré-agréger des données disponibles de façon plus détaillée dans les *data warehouse*, afin à traiter plus facilement certaines questions spécifiques, critiques, etc.


# Datamart

Un data warehouse et un *data mart* se distinguent par le spectre qu'il recouvre :

- Le *data warehouse* recouvre l'ensemble des données et problématiques d'analyse visées par l'entreprise.
- Le *data mart* recouvre une partie des données et problématiques liées à un métier ou un sujet d'analyse en particulier

Un *data mart* est fréquemment un sous-ensemble du *data warehouse* de l'entreprise, obtenu par extraction et agrégation des données de celui-ci.

# Datamart



# Datamart

Exemples :

Datamart commercial

Datamart recouvrement

Datamart Risque

Datamart controle de gestion

...



Datawarehouse de la banque



# Rappel


Qu'est que c'est l'informatique décisionnel ?

Quel est le rôle d'un entrepôt de donnée ?

Que représente un entrepôt de donnée techniquement parlant?

Quels sont les principaux éléments de l'architecture décisionnelle ?

Quelle est la différence entre analyser les données et explorer les données?





ETL



# ETL


- Extraire les données des sources hétérogènes (extract)
  - Identifier les données sources utiles
  - Déterminer les données qui ont changé
- Consolider les données (transform)
  - Données redondantes, manquantes, incohérentes, etc.
  - Découpage, fusion, conversion, aggrégation, etc.

# ETL

- Charger les données intégrées dans l'entrepôt (load)
  - Mode différé (batch) ou quasi temps-réel.
- Partie la plus longue du développement (jusqu'à 70% du temps total).

# ETL : Extraction des données (différée)

Extrait tous les changements survenus durant une période donnée (ex: heure, jour, semaine, mois).




# ETL : Extraction des données (différée)

- Option 1: Capture basée sur les timestamps
  - Une estampille (timestamp) d'écriture est ajoutée à chaque ligne des systèmes sources;
  - L'extraction se fait uniquement sur les données dont le timestamp est plus récent que la dernière extraction;
- Option 2: Capture par comparaison de fichiers
  - Compare deux snapshots successifs des données sources;
  - Extrait seulement les différences (ajouts, modifications, suppressions) entre les deux snapshots;
  - Exige de conserver une copie de l'état des données sources;
  - Approche relativement coûteuse.

# ETL: Extraction des données (temps réel)

S'effectue au moment où les transactions surviennent dans les systèmes sources.



# ETL: Extraction des données (temps réel)

- Option 1: Capture à l'aide du journal des transactions
  - Utilise les logs de transactions de la BD servant à la récupération en cas de panne;
  - Aucune modification requise à la BD ou aux sources;
  - Doit être fait avant le rafraîchissement périodique du journal;
- Option 2: Capture à l'aide de triggers
  - Des procédures déclenchées (triggers) sont définies dans la BD pour recopier les données à
  - extraire dans un fichier de sortie;
  - Meilleur contrôle de la capture d'évènements;
  - Exige de modifier les BD sources;



# ETL: Extraction des données (temps réel)

- Option 3: Capture à l'aide des applications sources
  - Les applications sources sont modifiées pour écrire chaque ajout et modification de données dans un fichier d'extraction;
  - Exige des modifications aux applications existantes;
  - Entraîne des coûts additionnels de développement et de maintenance;

# ETL : Transformation

- Révision de format:
  - Ex: Changer le type ou la longueur de champs individuels.
- Décodage de champs:
  - Ex: ['homme', 'femme'] vs ['M', 'F'] vs [1,2].
- Pré-calcul des valeurs dérivées:
  - Ex: profit calculé à partir de ventes et coûts.

# ETL: Transformation

- Découpage de champs complexes:
  - Ex: extraire les valeurs prénom, secondPrénom et nomFamille à partir d'une seule chaîne de caractères nomComplet.
- Pré-calcul des agrégations:
  - Ex: ventes par produit par semaine par région.
- Déduplication
  - Ex: Plusieurs enregistrements pour un même client

# ETL: Chargement des données

- Faire les chargements en lot dans une période creuse (entrepôt de données non utilisé);
- Considérer la bande passante requise pour le chargement;
- Avoir un plan pour évaluer la qualité des données chargées dans l'entrepôt;
- Commencer par charger les données des tables de dimension;
- Désactiver les indexes et clés étrangères lors du chargement.

# ETL: Flux de données

- **Flux entrant**

- Extraction: multi-source, hétérogène
- Transformation: filtrer, trier, homogénéiser, nettoyer
- Chargement: insertion des données dans l'entrepôt

- **Flux sortant**

- Mise à disposition des données pour les utilisateurs finaux